Microsoft Azure

# Ficou lento, e agora?

## *Como garantir a performance da sua aplicação no Azure*

**George Luiz Bittencourt**

## Sobre mim

SCAN ME

## George Luiz Bittencourt

Arquiteto de soluções cloud com mais de 20 anos de experiência em infraestrutura e desenvolvimento de software.

/glzbcrt

/glzbcrt

george.bittencourt@microsoft.com

# Azure Well-Architected Framework

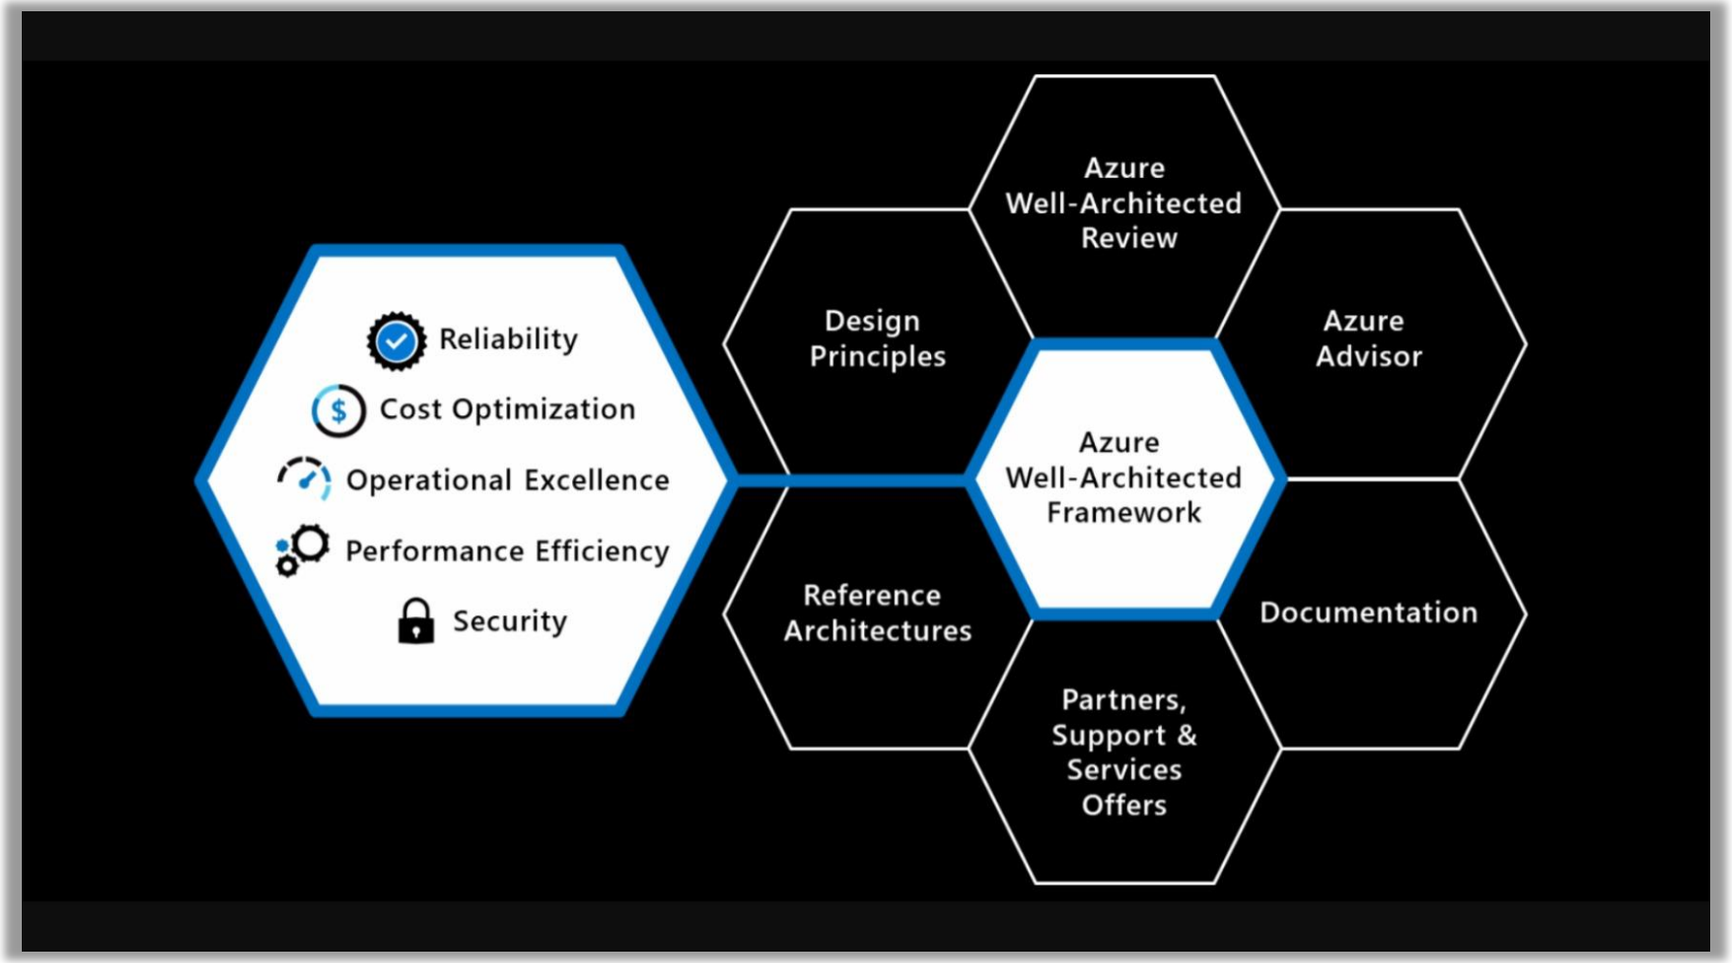


[Referência: Microsoft Azure Well-Architected Framework]

# Azure Well-Architected Framework

*Eficiência em performance é a capacidade de **ajustar** uma arquitetura de **forma manual ou automática** para **atender** a demanda dos **usuários**.*

# Azure Well-Architected Framework

Princípios

- Escalabilidade Horizontal
  - *Utilizar serviços gerenciados.*
  - *Escolher os componentes certos com os tamanhos corretos.*
- Shift-left dos testes de performance
  - *Executar testes de carga com cargas padrões e com a carga máxima esperada.*
  - *Estabelecer um baseline de performance.*
- Monitoramento contínuo em produção
  - *Avaliar de forma recorrente as alterações no uso dos componentes.*
  - *Criar alertas de monitoramento.*

# Livros Recomendados

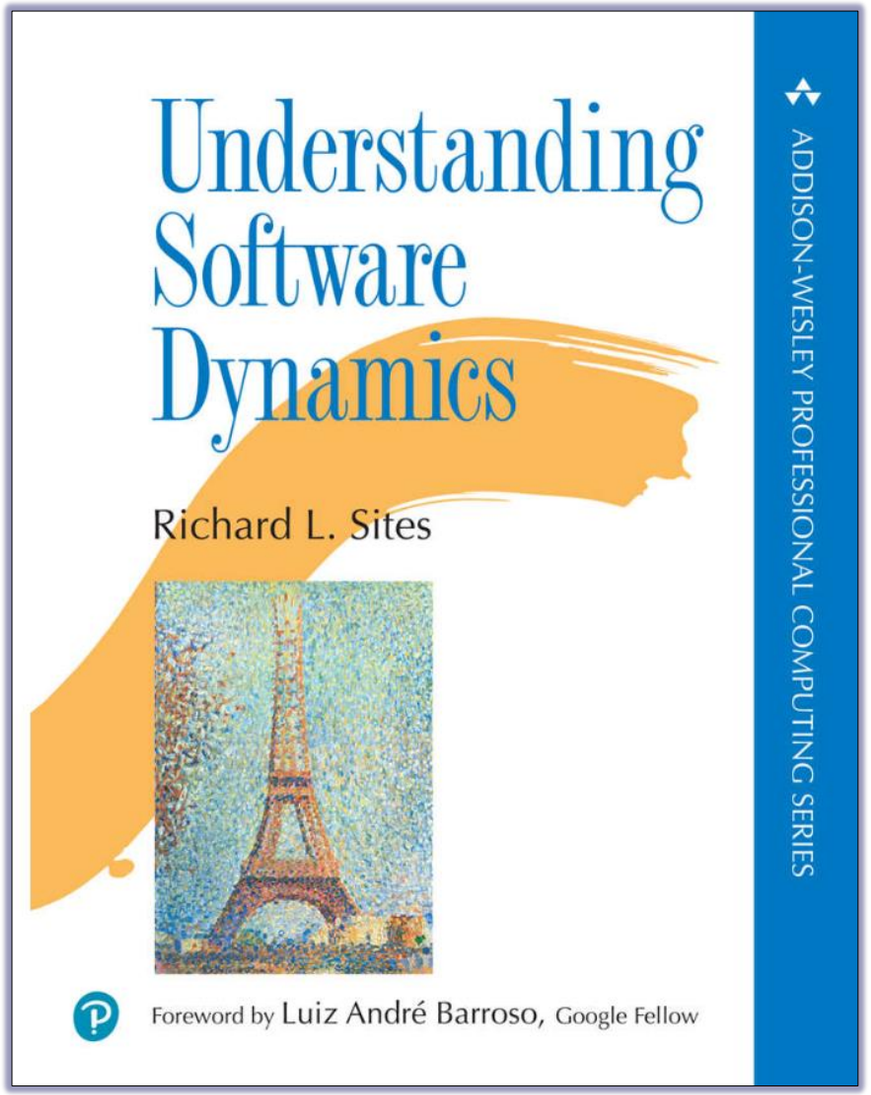


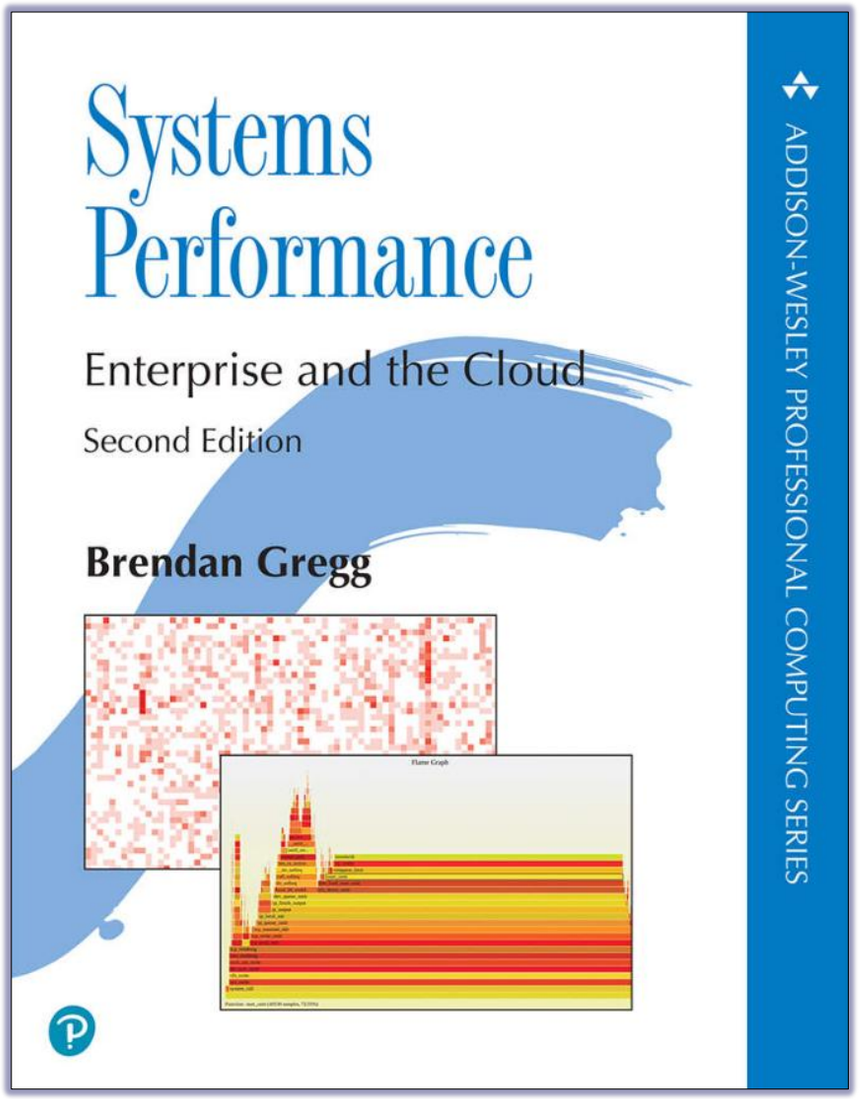

# Arquitetura de Referência

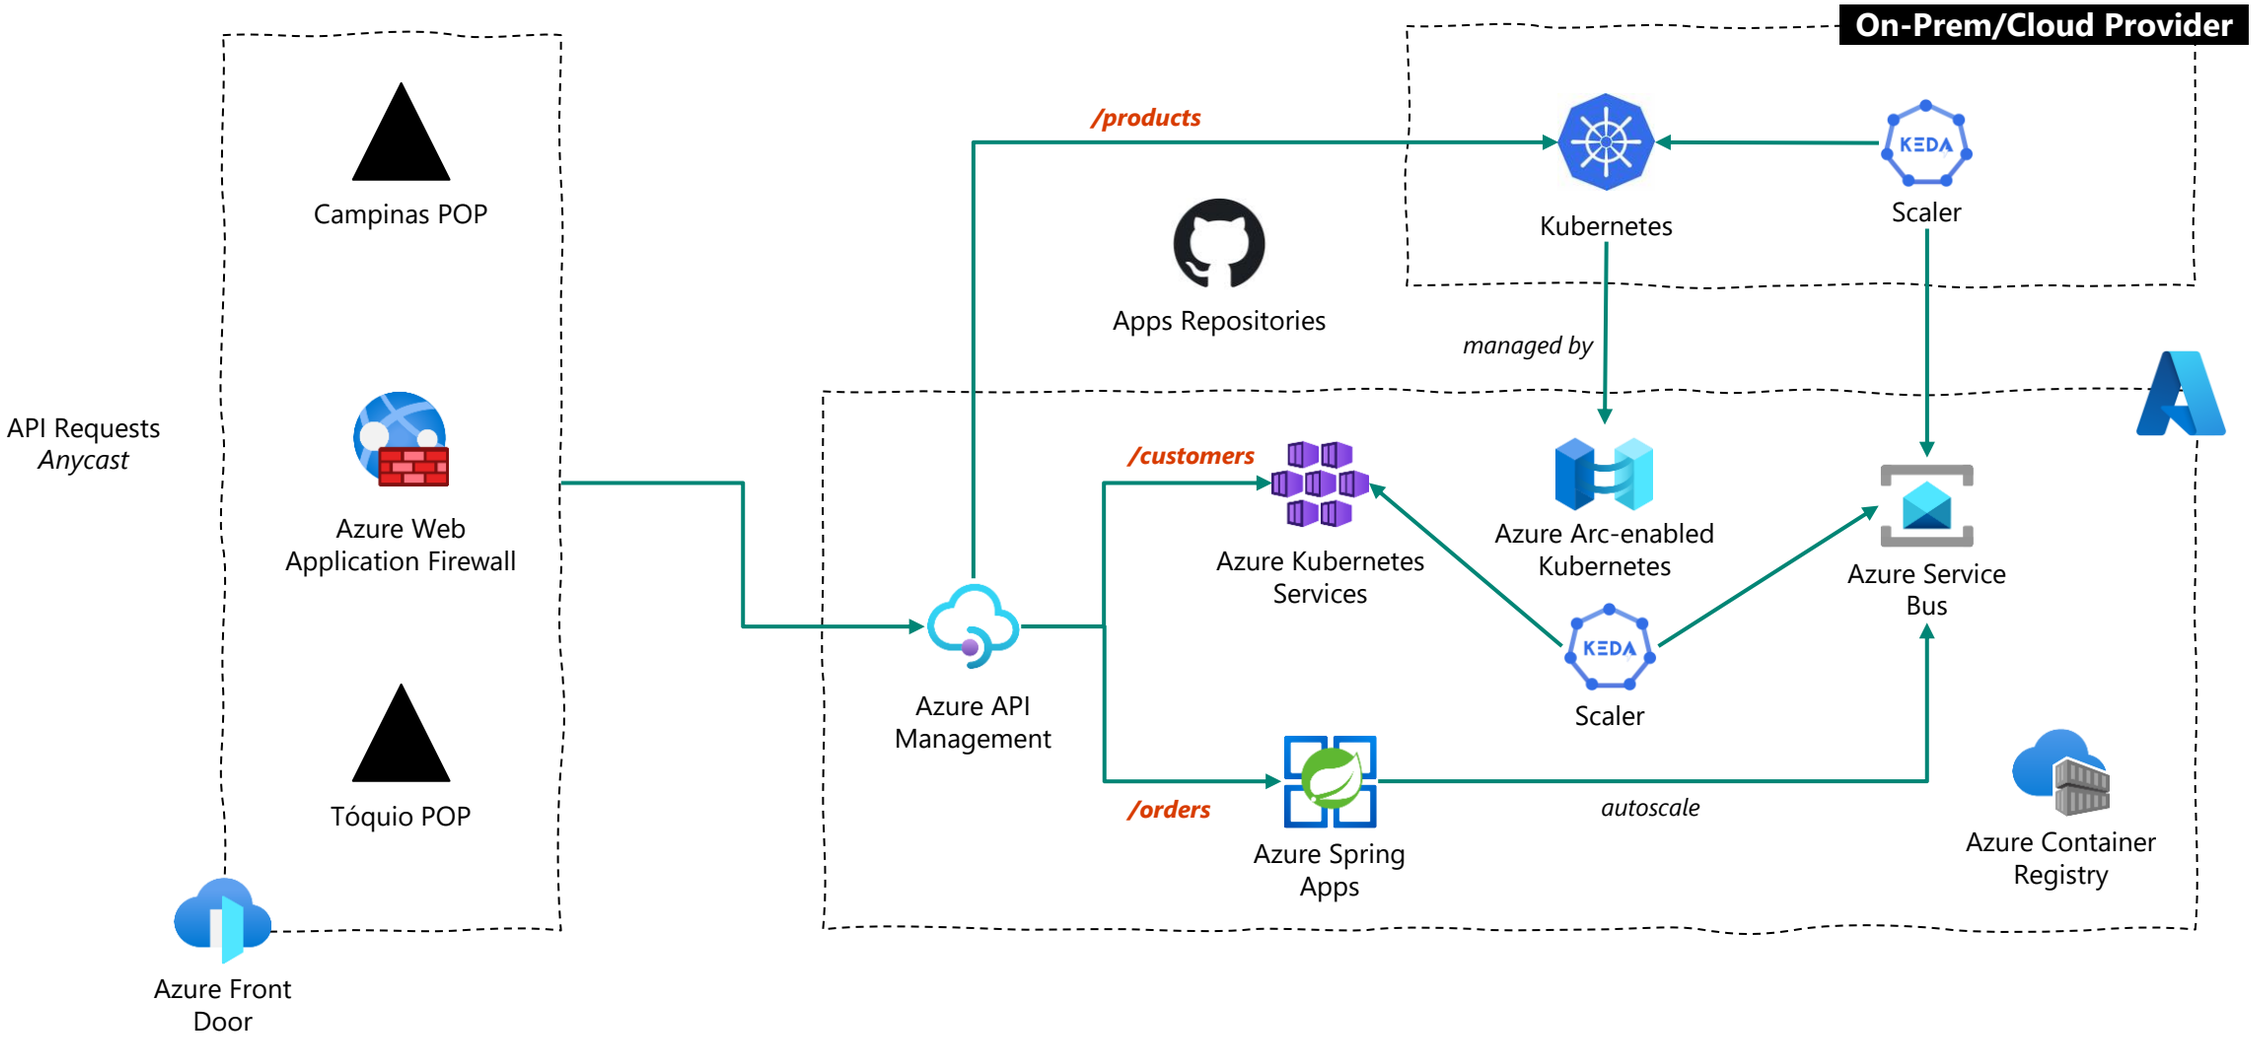

# Queueing Theory

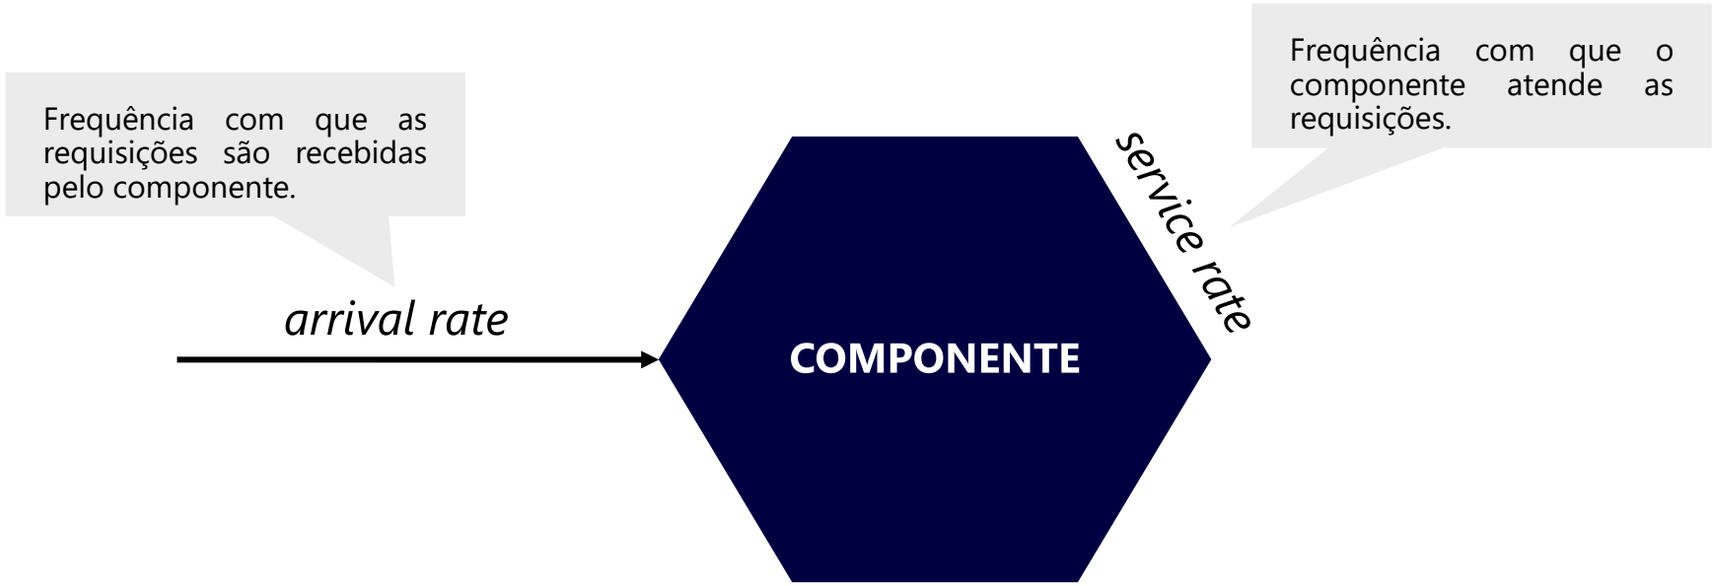


| Cenário | Descrição |
|---|---|
| Arrival Rate > Service Rate | Componente menor que o necessário para atender o demanda. Filas serão formadas, a latência vai aumentar e erros/timeouts vão ser gerados. |
| Arrival Rate < Service Rate | Componente maior que o necessário. As requisições serão atendidas com folga, porém um custo maior será gerado. |
| Arrival Rate = Service Rate | É o melhor cenário, o componente está com tamanho adequado atendendo as requisições e não existe custo ocioso. |

# Throughput, Taxa, Vazão

- De forma simples é a relação entre dois números.
  - Quantos megabytes eu gravo por segundo em um disco. Unidade → *MB/s*
  - Quantas requisições minha API responde por segundo. Unidade → *rps*
  - Quantos bytes de memória eu preciso para processar cada requisição. Unidade → *bytes/request*
  - *Quantos bits é possível enviar por segundo em uma conexão TCP de longa distância*. Unidade → *b/s*
- O *throughput* de um componente é o seu *service rate*, dessa forma quanto maior for, mais solicitações ela poderá atender sem gerar filas, timeouts, etc.
- Vários fatores influenciam no *throughput*, como:
  - Algoritmos e estruturas de dados escolhidas pelo componente.
  - Otimizações geradas pelos compiladores.
  - Contenções geradas por *locks* para serializar execuções.
  - Complexidade de componente.

# Latência e Resolução

- Latência
  - É o tempo entre dois eventos.
    - Quanto tempo leva para enviar um byte do ponto A para o ponto B?
    - Quanto tempo é necessário para alocar 1 MB de memória?
    - Quanto tempo um requisição leva para atender um GET com o dado em *cache* (cache hit)? E quando o dado não está em *cache* (cache miss)?
  - Em *networking* é muito utilizado e se mede o tempo de ida e volta de um pacote, conhecido como *round trip time*.
    - Quanto mais distante estamos do destino, maior é a latência. Nada é mais rápido que a velocidade de luz.
    - A rota e os roteadores também impactam na latência. Roteadores mais ocupados ou com problema tem latência maior.
  - Em *browsers* é comum a métrica Time to First Byte (TTFB).
- Resolução
  - É o menor valor que um sistema de medição pode medir.
    - Um sistema que mede o tempo em segundos não consegue medir um evento menor que um segundo.
    - Se coletamos o uso de CPU a cada minuto, o componente pode estar saturado em boa parte de um minuto e não teremos visibilidade.

# Conceitos Básicos

## Múltiplos

| Múltiplo | Símbolo | Valor |
|---|---|---|
| Quilo | k | $10^3$ |
| Mega | M | $10^6$ |
| Giga | G | $10^9$ |
| Tera | T | $10^{12}$ |
| Peta | P | $10^{15}$ |
| Exa | E | $10^{18}$ |

## Sub Múltiplos

| Múltiplo | Símbolo | Valor |
|---|---|---|
| Mili | m | $10^{-3}$ |
| Micro | μ | $10^{-6}$ |
| Nano | n | $10^{-9}$ |
| Pico | p | $10^{-12}$ |
| Femto | f | $10^{-15}$ |
| Atto | a | $10^{-18}$ |

# Workload Characterization

- O *workload characterization* é um método que pode ser utilizado tanto durante a fase de design quanto para resolver problemas em produção.
- Consiste em responder as 4 perguntas abaixo. Com elas é possível entender melhor a carga atual ou prevista para a aplicação.
  - **Quem** está causando a carga?
    - *Processo*
    - *Endereço IP*
    - *Usuário*
  - **Porque** a carga está sendo gerada?
    - *Qual é o stack trace gerando a carga?*
  - **Quais** são as características da carga?
    - *IOPS*
    - *througput*
    - *memória*
  - **Como** a carga está mudando com o passar do tempo?
    - *Alguma nova funcionalidade foi liberada?*
    - *O volume de usuários está aumentando com o passar do tempo?*

# USE

- O método **Utilization, Saturation, and Errors (USE)** é uma forma rápida de identificar a causa de um problema de performance.
- Consiste em avaliar três métricas dos recursos envolvidos na arquitetura.
- É importante ter um *baseline* para referência para diferenciar um comportamento normal de um anormal.
- *Utilization*:
  - *Qual é percentual de uso do componente em um intervalo?*
- *Saturation*:
  - *O componente está saturado?*
  - *Existe fila sendo gerada?*
- *Errors*:
  - *A quantidade de erros geradas.*

# Load Distribution

- Raramente a carga é distribuída de maneira homogênea no período.
- Cada métrica é uma série temporal e métricas de estatística descritiva podem ser utilizadas para entender a métrica, como: média, moda, percentil, desvio padrão, etc.
- A relação de uma métrica em relação a outra pode ser avaliada com o uso de correlação. Exemplo: como a CPU se comporta com o aumento da latência de disco.

| Hora | % CPU |
|---|---|
| 00:00 | 0 |
| 01:00 | 100 |
| 02:00 | 0 |
| 03:00 | 100 |
| 04:00 | 0 |
| 05:00 | 100 |
| 06:00 | 0 |
| 07:00 | 100 |
| 08:00 | 0 |
| 09:00 | 100 |
| 10:00 | 0 |
| 11:00 | 100 |

Média: 50%
Desvio Padrão: 50%
Percentil 90%: 100%

| Hora | % CPU |
|---|---|
| 00:00 | 5 |
| 01:00 | 80 |
| 02:00 | 30 |
| 03:00 | 0 |
| 04:00 | 20 |
| 05:00 | 66 |
| 06:00 | 100 |
| 07:00 | 100 |
| 08:00 | 75 |
| 09:00 | 45 |
| 10:00 | 20 |
| 11:00 | 100 |

Média: 53%
Desvio Padrão: 36%
Percentil 90%: 100%

| Hora | % CPU |
|---|---|
| 00:00 | 50 |
| 01:00 | 50 |
| 02:00 | 50 |
| 03:00 | 50 |
| 04:00 | 50 |
| 05:00 | 50 |
| 06:00 | 50 |
| 07:00 | 50 |
| 08:00 | 50 |
| 09:00 | 50 |
| 10:00 | 50 |
| 11:00 | 50 |

Média: 50%
Desvio Padrão: 0%
Percentil 90%: 50%

# E o código?

- Os algoritmos e estruturas de dados escolhidas tem papel fundamental no desempenho de um sistema.
  - Estruturadas de dados → arrays, linked list, map, etc.
  - Pesquisa → binary search, B tree, etc.
  - Ordenação → selection sort, quick sort, etc
- As dimensões espaço (memória e disco) e tempo (CPU) tem impacto direto nos recursos necessários.
- Em sua grande maioria os frameworks utilizadas utilizam bons algoritmos e estrutura de dados, porém casos específicos podem se beneficiar de algoritmos específicos.
- A notação *Big O* é fundamental na comparação de algoritmos.

# Arquitetura de Referência

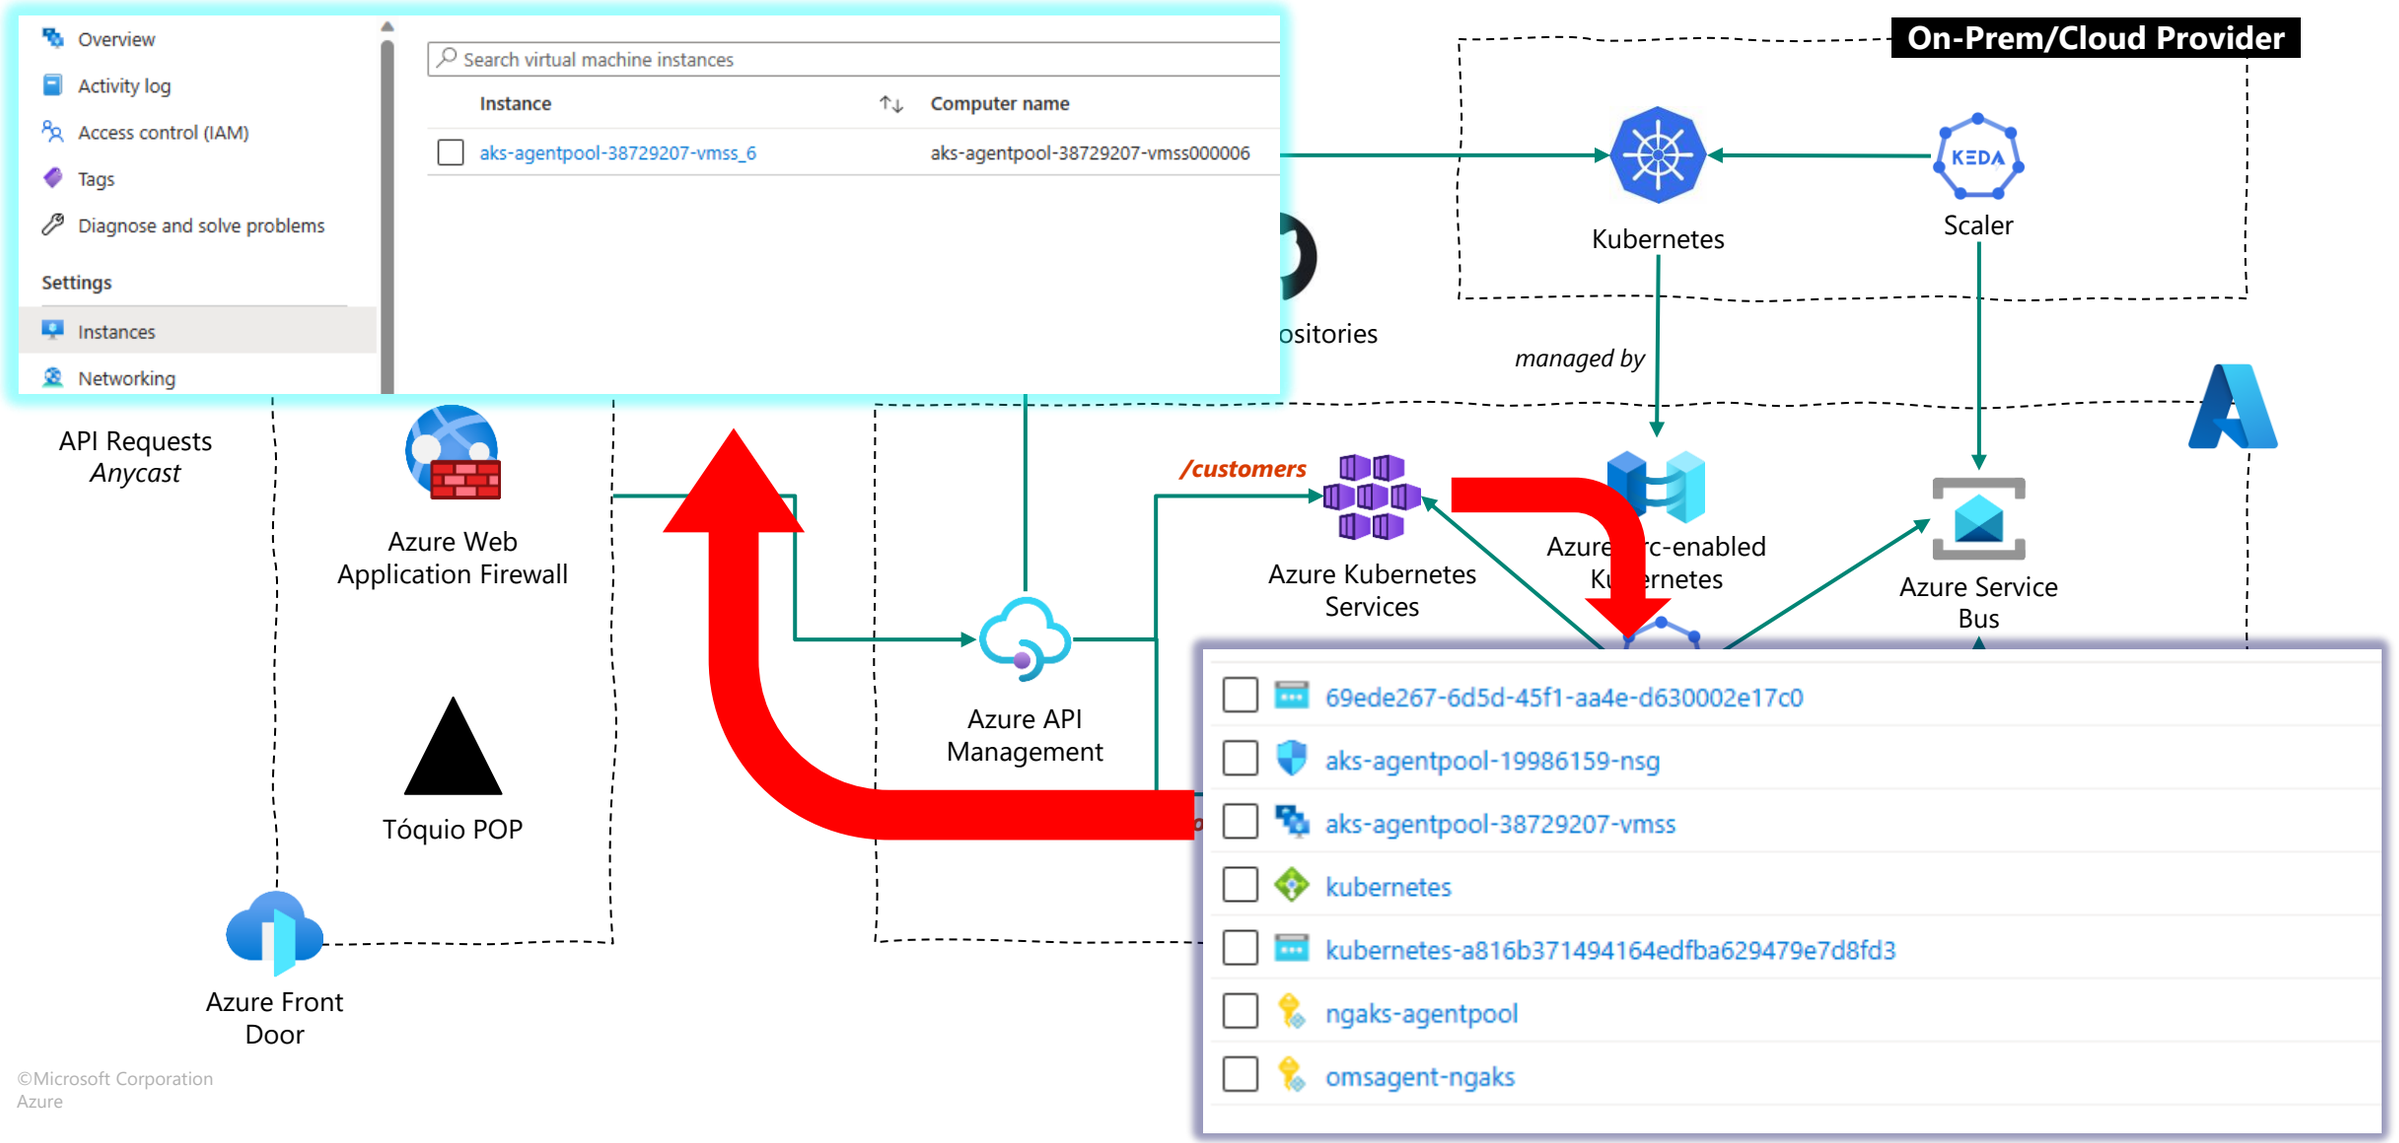

# Limites

- Todo componente, seja na nuvem ou *on-premisses*, possui limites.
- Componentes *on-premisses* acabam sendo super estimados já que o ambiente não é elástico.
- É importante entender os limites de cada componente durante a fase de arquitetura.
- Geralmente quando o componente atinge o seu limite ocorre *throttling* e a aplicação recebe alguma forma de erro.
- Alguns limites no Azure podem ser alterados através de *tickets* de suporte.
- Referência: Azure subscription limits and quotas
- Alguns exemplos:
  - Discos
  - Máquinas Virtuais
  - Storage Account

# Responsabilidade Compartilhada

## CLIENTE

- *Entender os limites de cada componente.*
- *Aplicar boas práticas de engenharia para tratar os limites.*
- *Monitorar a aplicação identificando os hot-spots e implementar soluções para transpor.*

## MICROSOFT

- *Disponibilizar **serviços** com performance adequada.*
- *Documentar os limites de cada serviço e seus custos.*
- *Fornecer observabilidade dos componentes.*
- *Documentar boas práticas e arquiteturas de referência.*

# Benchmark Disco

- Mede a performance de um conjunto de discos com base em um *workload* sintético.
- O ideal é que *workload* sintético seja o mais representativo possível do *workload* real.
- Operações de gravação são mais onerosas que operações de leitura.
- Fatores importantes a serem considerados:
  - HDD vs SSD
  - % de gravações VS % de leituras
  - operações sequencias VS operações aleatórias
  - tamanho do bloco utilizado (4kiB, 1MiB, etc)
  - uso de cache de leitura e/ou gravação
  - multi-thread
  - queue depth
  - limites do disco e da máquina virtual
- Ferramentas:
  - diskspd: ferramenta da Microsoft para Windows desenvolvida de forma *open-source*.
  - fio: ferramenta *open-source* para Linux.

Microsoft Azure

# DEMO

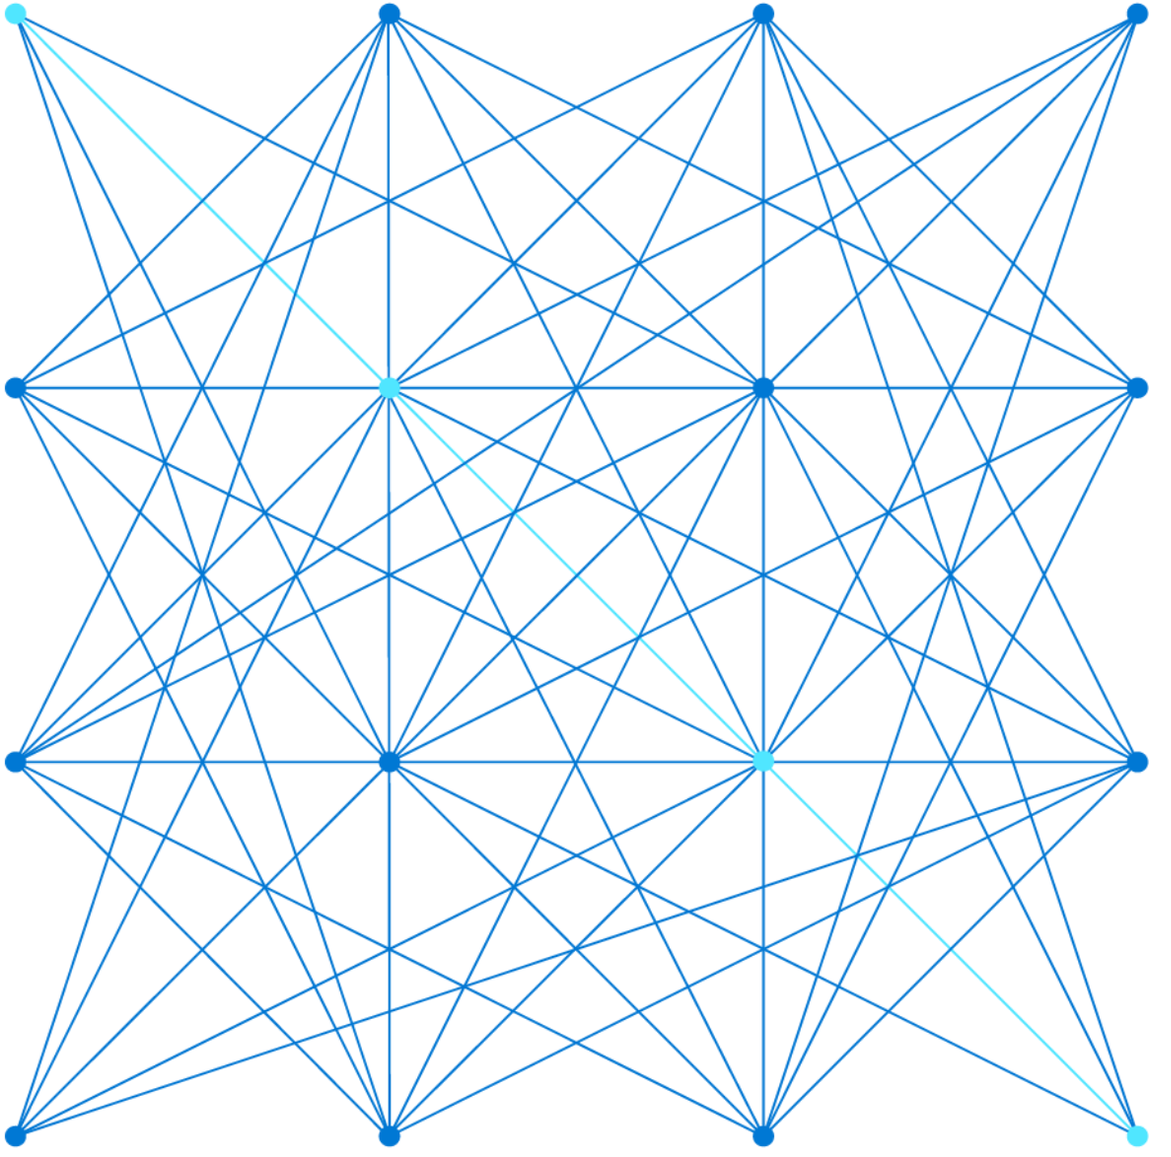

# Benchmark Rede

- Mede a performance entre dois pontos da rede.
- Pontos diferentes podem ter performance diferente.
- Conexões TCP com alta latência tem througput baixo.
- Fatores importantes a serem considerados:
  - distância física entre os pontos
  - largura de banda disponível
  - saturação dos componentes
  - VPN, WAF, IDPS, etc
  - fragmentação
  - quantidade de conexões
  - limites da máquina virtual
- Ferramentas:
  - iperf: ferramenta open-source para Windows e Linux.

Microsoft Azure

# DEMO

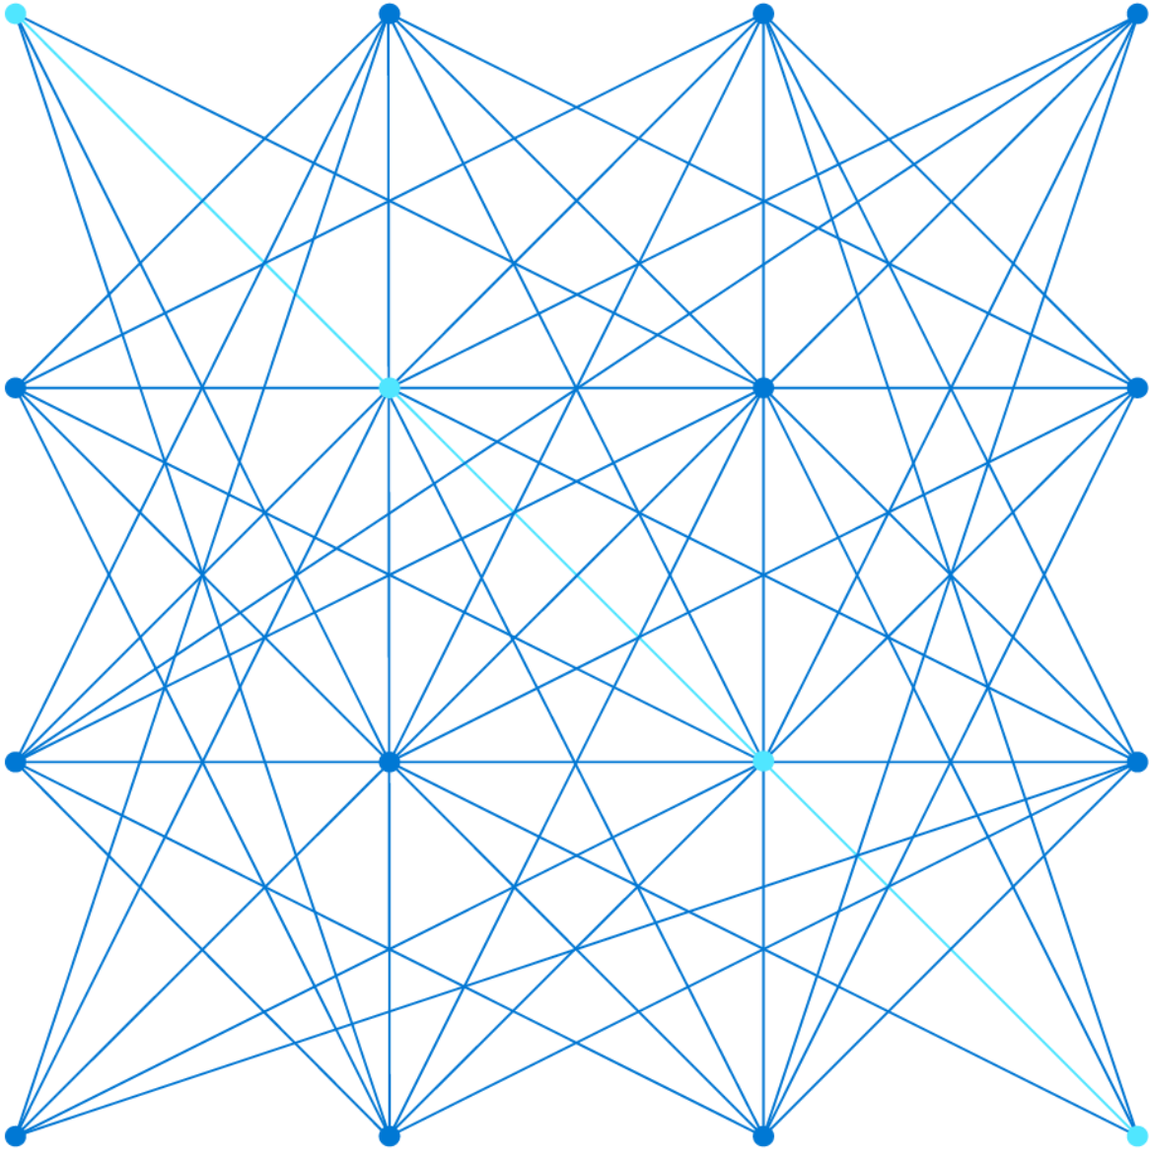

# Benchmark CPU

- Processadores diferentes tem performances diferentes.
- Fatores importantes a serem considerados:
  - clock
  - quantidade de cache L1, L2, L3
  - instruções suportadas para operações específicas como criptografia, multimídia, etc.
  - hypter-threading
  - # de cores
  - NUMA vs UMA
  - memória
  - compiladores e possíveis otimizações
- Ferramentas
  - BenchmarkDotNet: ferramenta *open-source* para executar benchmark de códigos .NET.

# Benchmark APIs

- Fatores importantes a serem considerados:
  - formato utilizado (JSON, ProtoBuf, etc)
  - chamadas únicas VS chamadas em batch
  - SSL Offloading vs SSL E2E
  - uso de cache
- Ferramentas
  - Azure Load Testing
  - K6
  - jMeter

# Ferramentas

- Azure
  - Metrics disponíveis em cada recurso
  - Application Insights
  - Azure Load Testing
- Windows
  - Performance Monitor
  - Process Monitor
  - Event Tracing for Windows (ETW)
  - PerfView
- Linux
  - iostat, vmstat, lsof, strace, tcpdump, etc
  - eBPF
- Geral
  - Profilers de CPU e memória:
    - dotTrace, dotMemory
    - JProfiler

# Flame Graphs

- É uma forma de visualização para entender rapidamente onde o tempo está sendo mais dispendido.
- No eixo X temos as funções e no eixo Y a profundidade da pilha de chamadas. Quanto maior a largura de uma função, mais tempo ela esteve presente.
- Referência: [Flame Graphs (brendangregg.com)]

Microsoft Azure

# DEMO

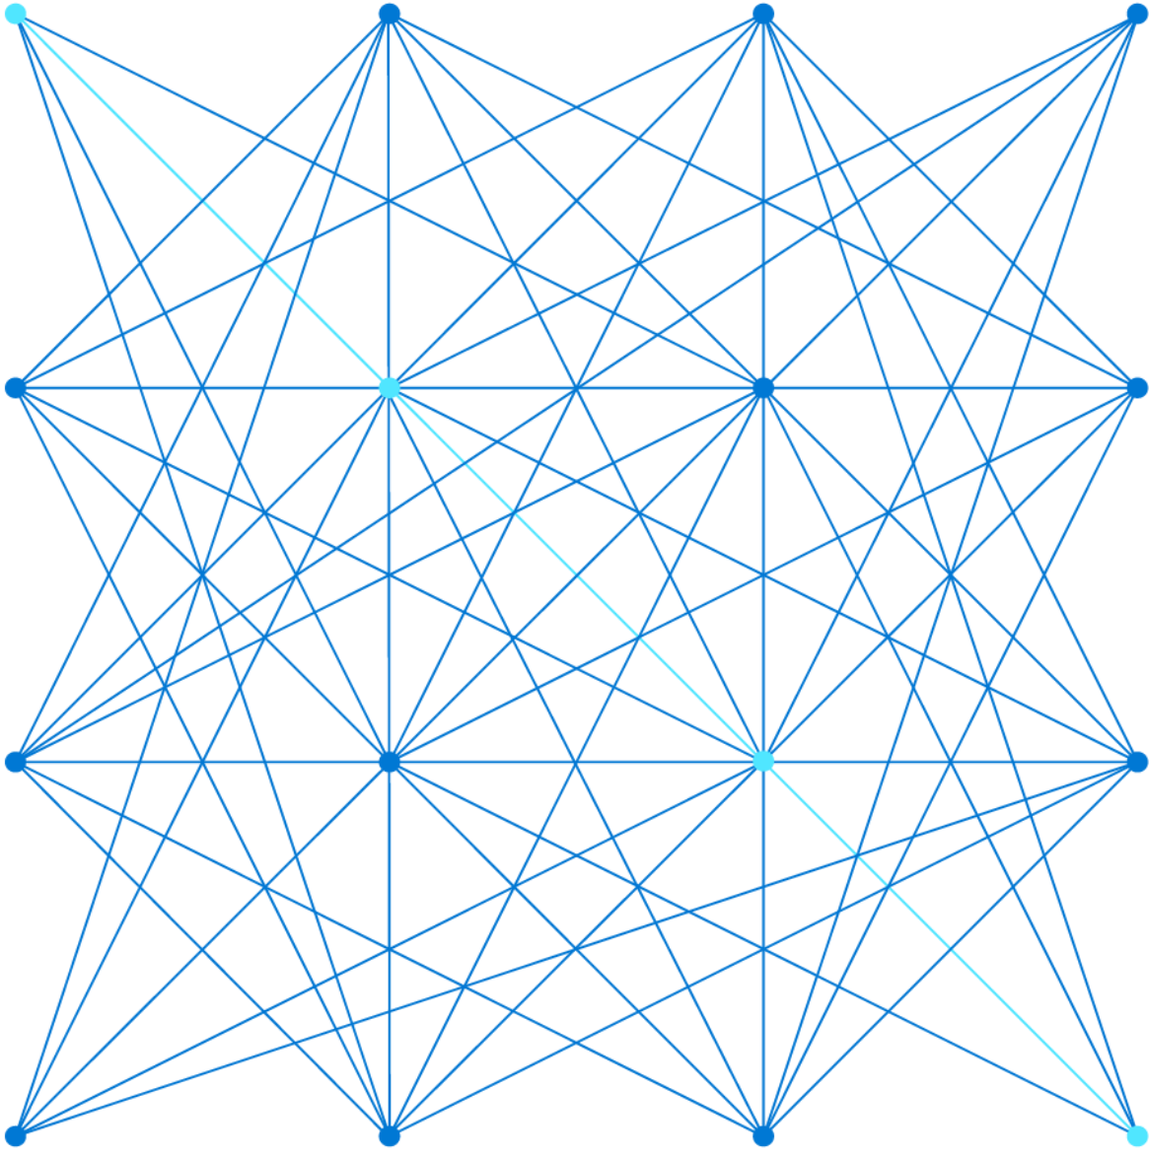

# Checklist

- ✓ Os limites de cada componente utilizado na arquitetura são conhecidos?
- ✓ Os componentes selecionados escalam de forma horizontal?
- ✓ Foram efetuados testes de performance? Foi criado um baseline de performance?
- ✓ A carga esperada foi definida?
- ✓ Estão sendo utilizadas políticas de auto-scale?
- ✓ O código utiliza algoritmos e estrutura de dados corretas?
- ✓ Onde é possível, está sendo utilizado cache?
- ✓ Os dados estão particionados horizontalmente?

Microsoft Azure

# EOF

/glzbcrt

/glzbcrt

george.bittencourt@microsoft.com

SCAN ME